

FGV EMap
Ciência de Dados e Inteligência Artificial

Maria Eduarda Mesquita Magalhães

Robustificação de Carteiras de Mínima Variância com Ativos Brasileiros

Uma aplicação da estimação robusta de Σw ao problema de Markowitz

Trabalho em formato de relatório técnico-científico apresentado como material de apoio para estudo de Estatística Robusta aplicada à otimização de carteiras.

Orientador(a): Philip Thompson

Brasil
3 de julho de 2026

Resumo

Este trabalho investiga se carteiras global minimum variance (GMV) robustificadas por estimação robusta da ação da covariância, Σw , apresentam menor instabilidade de pesos e melhor desempenho líquido fora da amostra do que carteiras GMV baseadas em covariância amostral e estimadores de shrinkage, quando aplicadas a ativos do mercado brasileiro. O estudo reproduz a lógica central do artigo *Robustifying Markowitz*, adaptando o universo empírico para ativos brasileiros, usando janelas móveis de $T = 252$ e $T = 500$ dias, rebalanceamento mensal, custos de transação de 50 pontos-base e comparação com benchmarks como Equal Weight, GMV amostral, GMV Long Only, shrinkage linear, nonlinear shrinkage e índice de mercado. Além de documentar a metodologia computacional adotada, o texto apresenta as equações fundamentais de Markowitz, projected gradient descent, projeção orçamentária, estimadores robustos sob caudas pesadas e agregação Hopkins–Li–Zhang (HLZ). Os resultados indicam que a carteira robusta melhora a estabilidade frente à GMV amostral e aos métodos de shrinkage em termos de turnover, apresentando desempenho líquido competitivo e, em alguns cenários, superior em Sharpe ou Calmar.

Palavras-chave: Estatística Robusta; Markowitz; GMV; caudas pesadas; shrinkage; mercado brasileiro.

Abstract

This report studies whether robustified global minimum variance portfolios, based on robust estimation of the covariance action Σw , display lower weight instability and better net out-of-sample performance than GMV portfolios based on sample covariance and shrinkage estimators when applied to Brazilian equities. The project follows the central logic of *Robustifying Markowitz*, replacing the original empirical universe with Brazilian assets, using rolling windows of $T = 252$ and $T = 500$ trading days, monthly rebalancing, transaction costs of 50 basis points and comparisons against standard benchmarks. The report also explains the mathematical structure of the repository, including GMV optimization, projected gradient descent, budget projection, robust estimation under heavy tails and the Hopkins–Li–Zhang spectral reweighting procedure. The empirical results suggest that the robust GMV portfolio reduces turnover relative to sample GMV and shrinkage methods while remaining competitive, and sometimes superior, in risk-adjusted net performance.

Keywords: Robust Statistics; Markowitz; GMV; heavy tails; shrinkage; Brazilian stock market.

Sumário

Resumo	i
Abstract	ii
1 Visão geral do projeto	1
1.1 Pergunta de pesquisa	1
1.2 Hipótese de pesquisa	1
1.3 Objetivos	2
1.4 Contribuição do trabalho	2
1.5 Procedimento metodológico	2
2 Por que Estatística Robusta entra no problema?	3
2.1 O problema das caudas pesadas	3
2.2 Robustez	3
3 Carteira de mínima variância global	4
3.1 Retornos e pesos	4
3.2 Problema GMV	4
4 Projected Gradient Descent	4
4.1 Projeção orçamentária	5
5 A ideia robusta: estimar Σw, não Σ	5
6 Como o projeto estima Σw	5
6.1 Centralização por pares	5
6.2 Blocos e truncagem	6
6.3 Agregação HLZ / spectral sample reweighting	6
6.3.1 Passos do algoritmo HLZ usado no experimento	6
7 Benchmarks implementados	7
7.1 Equal Weight	7
7.2 GMV amostral	7
7.3 GMV Long Only	7
7.4 Linear Shrinkage	8
7.5 Nonlinear Shrinkage	8
7.6 GMV Robust	8
8 Dados brasileiros	8
9 Backtest	8
9.1 Janelas móveis	8
9.2 Retornos brutos e líquidos	9
9.3 Turnover	9

10 Métricas	9
10.1 Riqueza acumulada	9
10.2 Volatilidade anualizada	9
10.3 Sharpe Ratio	9
10.4 Maximum Drawdown e Calmar	10
10.5 Estatísticas dos pesos	10
11 Testes estatísticos	10
12 Resultados empíricos recentes	11
12.1 Janela $T = 252$	11
12.1.1 Gráficos para $T = 252$	11
12.2 Janela $T = 500$	14
12.2.1 Gráficos para $T = 500$	14
13 Conclusões do experimento	14
14 Validações metodológicas	17
14.1 Auditoria HLZ	17
14.2 Validação do nonlinear shrinkage	17
15 Limitações e pontos de atenção	17
16 Conclusão	17

Lista de Figuras

1	Riqueza acumulada líquida para a janela de estimação $T = 252$	12
2	Turnover das carteiras para a janela $T = 252$	12
3	Pesos da carteira GMV Robust ao longo do tempo para $T = 252$	13
4	Distribuição dos pesos das carteiras para $T = 252$	13
5	Riqueza acumulada líquida para a janela de estimação $T = 500$	14
6	Turnover das carteiras para a janela $T = 500$	15
7	Pesos da carteira GMV Robust ao longo do tempo para $T = 500$	15
8	Distribuição dos pesos das carteiras para $T = 500$	16

Lista de Tabelas

1	Procedimento metodológico executado no estudo.	2
2	Resultados líquidos das carteiras para janela de estimação $T = 252$	11
3	Resultados líquidos das carteiras para janela de estimação $T = 500$	12

1 Visão geral do projeto

O projeto parte de uma pergunta prática:

Como construir carteiras de mínima variância que sejam menos sensíveis a erros de estimação, caudas pesadas e mudanças bruscas nos pesos, usando dados do mercado brasileiro?

O artigo *Robustifying Markowitz* argumenta que a implementação clássica de Markowitz, baseada em média e covariância amostrais, pode gerar pesos instáveis e altos custos de transação. A contribuição principal do artigo não é simplesmente trocar a covariância amostral por uma “covariância robusta”. A ideia central é mais sutil:

Em vez de estimar uma matriz de covariância robusta completa e depois invertê-la, estima-se robustamente apenas a ação da covariância sobre o vetor de pesos atual, isto é, Σw , dentro de um algoritmo iterativo de gradiente projetado.

Neste trabalho, essa lógica foi aplicada a um universo brasileiro congelado baseado no Ibovespa. O experimento roda duas janelas de estimação, $T = 252$ e $T = 500$, usa custo de transação de 50 bps e compara a carteira robusta contra benchmarks usuais.

1.1 Pergunta de pesquisa

A pergunta que orienta este trabalho é:

Carteiras GMV robustificadas por estimação robusta de Σw apresentam menor instabilidade de pesos e melhor desempenho líquido fora da amostra do que carteiras GMV baseadas em covariância amostral e shrinkage, quando aplicadas a ativos do mercado brasileiro?

Essa pergunta é adequada porque conecta diretamente a teoria estatística à aplicação empírica. O objeto Σw é o gradiente do problema GMV; portanto, estimá-lo bem é essencial para obter pesos estáveis. Ao mesmo tempo, o desempenho fora da amostra e o turnover verificam se a melhora matemática se traduz em uma carteira operacionalmente útil.

1.2 Hipótese de pesquisa

A hipótese de pesquisa adotada é:

Hipótese de pesquisa: carteiras GMV robustificadas por estimação robusta de Σw apresentam menor instabilidade de pesos e melhor desempenho líquido fora da amostra do que carteiras GMV baseadas em covariância amostral e shrinkage, quando aplicadas a ativos do mercado brasileiro.

Em termos empíricos, essa hipótese será avaliada por métricas de desempenho líquido, como Sharpe e Calmar, e por métricas de estabilidade, como turnover, target turnover e distribuição dos pesos.

1.3 Objetivos

O objetivo geral é adaptar a lógica do artigo *Robustifying Markowitz* para um universo de ativos brasileiros e avaliar se a robustificação melhora a estabilidade e o desempenho líquido das carteiras GMV.

Os objetivos específicos são:

1. preparar uma base de preços ajustados de ativos brasileiros e do índice de mercado;
2. calcular retornos e construir janelas móveis de estimação;
3. implementar carteiras EW, GMV amostral, GMV Long Only, GMV com shrinkage linear, GMV com nonlinear shrinkage e GMV Robust;
4. implementar a otimização por projected gradient descent com projeção orçamentária;
5. aplicar estimação robusta de Σw usando blocos, truncagem e agregação HLZ;
6. executar backtests com rebalanceamento mensal e custos de transação;
7. comparar as carteiras por retorno, volatilidade, Sharpe, Calmar, drawdown, turnover e estatísticas dos pesos.

1.4 Contribuição do trabalho

A contribuição deste trabalho é dupla. Do ponto de vista didático, o relatório traduz a matemática do artigo para uma sequência implementável e comentada. Do ponto de vista empírico, o projeto aplica a metodologia a ativos brasileiros, mantendo a estrutura central do paper: não se estima uma covariância robusta completa para depois invertê-la; estima-se robustamente a ação Σw dentro do algoritmo de otimização.

1.5 Procedimento metodológico

O experimento foi conduzido de forma sequencial, da preparação dos dados à análise dos resultados. A Tabela 1 resume a ordem das etapas.

Tabela 1: Procedimento metodológico executado no estudo.

Etapa	Descrição
1	Seleção do universo brasileiro de ações, com congelamento dos ativos elegíveis para manter a reprodutibilidade.
2	Coleta e limpeza dos preços ajustados, removendo séries insuficientes ou incompatíveis com as janelas de estimação.
3	Cálculo dos retornos simples diários a partir dos preços ajustados.
4	Construção de janelas móveis de estimação com $T = 252$ e $T = 500$ observações.
5	Estimação das matrizes ou ações de covariância necessárias para cada carteira: covariância amostral, shrinkage linear, nonlinear shrinkage e estimação robusta de Σw .

6	Otimização das carteiras EW, GMV amostral, GMV Long Only, GMV Linear Shrinkage, GMV Nonlinear Shrinkage e GMV Robust.
7	Rebalanceamento mensal das carteiras, mantendo os pesos entre datas de rebalanceamento.
8	Cálculo dos retornos brutos e líquidos, descontando custo de transação de 50 pontos-base proporcional ao turnover.
9	Cálculo das métricas de desempenho, risco e estabilidade dos pesos.
10	Geração das tabelas, figuras e interpretação dos resultados em relação à hipótese de pesquisa.

2 Por que Estatística Robusta entra no problema?

2.1 O problema das caudas pesadas

Em muitos modelos elementares, assume-se que retornos financeiros são aproximadamente normais. Na prática, retornos de ativos frequentemente têm:

- assimetria;
- curtose elevada;
- outliers;
- períodos de estresse em que correlações mudam rapidamente.

Dizemos que uma distribuição possui *caudas pesadas* quando eventos extremos são mais prováveis do que seriam em uma distribuição normal. Isso afeta diretamente estimadores clássicos como a média amostral e a covariância amostral.

Se $X_1, \dots, X_T \in \mathbb{R}^N$ são vetores de retornos, a covariância amostral é

$$\hat{\Sigma} = \frac{1}{T-1} \sum_{t=1}^T (X_t - \bar{X})(X_t - \bar{X})^\top, \quad \bar{X} = \frac{1}{T} \sum_{t=1}^T X_t. \quad (1)$$

Sob normalidade e amostras grandes, esse estimador é natural. Sob caudas pesadas, poucos observações extremas podem deslocar muito $\hat{\Sigma}$. Em Markowitz, pequenas perturbações em $\hat{\Sigma}$ podem gerar grandes mudanças em w , pois a solução clássica envolve uma inversão de matriz.

2.2 Robustez

Um estimador robusto é desenhado para manter desempenho razoável quando as hipóteses ideais falham. Neste projeto, robustez significa principalmente:

- reduzir a influência de observações extremas;
- evitar a inversão direta de matrizes mal condicionadas;
- estabilizar pesos ao longo do tempo;
- reduzir turnover e custos de transação.

Essa visão vem da literatura moderna de estimação robusta em alta dimensão, incluindo Lugosi e Mendelson, Hopkins, Li e Zhang, e os resultados usados pelo artigo *Robustifying Markowitz*.

3 Carteira de mínima variância global

3.1 Retornos e pesos

Considere N ativos. Em um dia t , escrevemos o vetor de retornos como

$$X_t = (r_{1,t}, r_{2,t}, \dots, r_{N,t})^\top \in \mathbb{R}^N. \quad (2)$$

Uma carteira é um vetor de pesos

$$w = (w_1, \dots, w_N)^\top, \quad (3)$$

em que w_i é a fração alocada no ativo i . A restrição orçamentária é

$$\mathbf{1}^\top w = 1. \quad (4)$$

O retorno da carteira no dia t é

$$R_{p,t} = w^\top X_t. \quad (5)$$

Se $\Sigma = \text{Cov}(X_t)$ é a matriz de covariância populacional, a variância da carteira é

$$\text{Var}(R_{p,t}) = w^\top \Sigma w. \quad (6)$$

3.2 Problema GMV

A carteira global minimum variance (GMV) minimiza risco sem usar estimativas de retorno esperado:

$$w^* = \arg \min_{w \in \mathbb{R}^N} \frac{1}{2} w^\top \Sigma w \quad \text{sujeito a} \quad \mathbf{1}^\top w = 1. \quad (7)$$

O fator $1/2$ é usado por conveniência, pois o gradiente fica

$$\nabla_w \left(\frac{1}{2} w^\top \Sigma w \right) = \Sigma w. \quad (8)$$

Quando Σ é inversível, a solução fechada é

$$w^* = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}. \quad (9)$$

Na prática, Σ é desconhecida e substituída por algum estimador. O problema é que (9) pode ser instável quando a covariância estimada é ruidosa ou mal condicionada.

4 Projected Gradient Descent

O artigo usa projected gradient descent (PGD) para resolver o problema GMV sem depender diretamente de uma inversão matricial. A atualização ideal, se Σ fosse conhecida, seria

$$w_s = \Pi_1 [w_{s-1} - \eta \Sigma w_{s-1}], \quad s = 1, 2, \dots, \quad (10)$$

em que $\eta > 0$ é o passo e Π_1 é a projeção no hiperplano $\mathbf{1}^\top w = 1$.

4.1 Projeção orçamentária

A projeção usada no artigo é

$$\Pi_1 x = \left(I - \frac{1}{N} \mathbf{1}\mathbf{1}^\top \right) x + \frac{1}{N} \mathbf{1}. \quad (11)$$

Essa projeção garante que os pesos somem 1, mas **não** impõe $w_i \geq 0$. Portanto, ela permite posições vendidas. Isso é importante: a carteira robusta do artigo procura estabilidade sem impor uma restrição long-only a priori.

5 A ideia robusta: estimar Σw , não Σ

O ponto mais importante do artigo é trocar a estimação de uma matriz inteira por uma estimação robusta da ação dessa matriz:

$$\Sigma w. \quad (12)$$

Se $\mathbb{E}X = 0$, então

$$\Sigma w = \mathbb{E} [X X^\top w] = \mathbb{E} [X (X^\top w)]. \quad (13)$$

Assim, para um w fixo, estimar Σw vira um problema de estimação robusta de média vetorial aplicada aos vetores

$$Y_t(w) = X_t(X_t^\top w). \quad (14)$$

No PGD robusto, a atualização torna-se

$$w_s = \Pi_1 [w_{s-1} - \eta \hat{a}(w_{s-1})], \quad (15)$$

em que $\hat{a}(w)$ é um estimador robusto de Σw .

6 Como o projeto estima Σw

O artigo descreve quatro ideias principais:

1. centralizar as observações sem estimar a média;
2. dividir a amostra em blocos;
3. truncar observações extremas por norma;
4. agregar os vetores de bloco via spectral sample reweighting do tipo HLZ.

6.1 Centralização por pares

Para evitar depender de uma estimativa da média, o artigo usa diferenças pareadas:

$$\tilde{X}_1 = \frac{X_1 - X_2}{\sqrt{2}}, \quad \tilde{X}_2 = \frac{X_3 - X_4}{\sqrt{2}}, \quad \dots \quad (16)$$

Se X_i são independentes com covariância Σ , então

$$\text{Cov} \left(\frac{X_1 - X_2}{\sqrt{2}} \right) = \frac{1}{2} (\text{Cov}(X_1) + \text{Cov}(X_2)) = \Sigma. \quad (17)$$

Logo, a transformação remove a média, mas preserva a covariância. Essa é a primeira etapa da estimação robusta usada no experimento.

6.2 Blocos e truncagem

Depois da centralização, os dados são divididos em ℓ blocos. O artigo usa heurísticamente $\ell = 10$ e $\epsilon = 1/3$ nos experimentos empíricos. O projeto segue essa escolha.

Para cada bloco B_j , calcula-se uma ação de covariância robustificada:

$$\widehat{\Sigma}_j w = \frac{1}{|B_j|} \sum_{i \in B_j} \tilde{X}_i (\tilde{X}_i^\top w) \mathbf{1}_{\|\tilde{X}_i\| \leq D}. \quad (18)$$

No projeto, o limiar D é operacionalizado por quantil da norma, via `trim_quantile`. Isso é uma escolha prática: o artigo observa que o parâmetro teórico exato depende de quantidades desconhecidas, como posto efetivo e constantes de cauda.

6.3 Agregação HLZ / spectral sample reweighting

O projeto implementa um agregador baseado em Hopkins, Li e Zhang (HLZ), especificamente na formulação de *spectral sample reweighting*. A entrada do agregador são os vetores de bloco:

$$Z_j = \widehat{\Sigma}_j w, \quad j = 1, \dots, \ell. \quad (19)$$

A ideia é encontrar pesos u_j e um centro ν que minimizem a maior direção de dispersão:

$$\lambda_{\max} \left(\sum_{j=1}^{\ell} u_j (Z_j - \nu)(Z_j - \nu)^\top \right). \quad (20)$$

Os pesos pertencem ao simplex capado

$$W_{\ell, \epsilon} = \left\{ u \in \Delta_\ell : \|u\|_\infty \leq \frac{1}{(1 - \epsilon)\ell} \right\}. \quad (21)$$

Essa restrição impede que o algoritmo coloque peso demais em poucos blocos.

6.3.1 Passos do algoritmo HLZ usado no experimento

A versão operacional do algoritmo tipo Filter/MWU segue os seguintes passos:

1. Comece com pesos uniformes $u_j^{(0)} = 1/\ell$.
2. Calcule o centro ponderado

$$\nu^{(t)} = \sum_{j=1}^{\ell} u_j^{(t)} Z_j. \quad (22)$$

3. Calcule a matriz de dispersão ponderada

$$M^{(t)} = \sum_{j=1}^{\ell} u_j^{(t)} (Z_j - \nu^{(t)})(Z_j - \nu^{(t)})^\top. \quad (23)$$

4. Encontre o autovetor $v^{(t)}$ associado ao maior autovalor de $M^{(t)}$.

5. Defina perdas quadráticas

$$\tau_j^{(t)} = \left(v^{(t)\top} (Z_j - \nu^{(t)}) \right)^2. \quad (24)$$

6. Atualize pesos por multiplicative weights:

$$\tilde{u}_j^{(t+1)} = u_j^{(t)} \left(1 - \eta \frac{\tau_j^{(t)}}{\rho} \right). \quad (25)$$

7. Projete por divergência KL no conjunto $W_{\ell, \epsilon}$:

$$u^{(t+1)} = \arg \min_{u \in W_{\ell, \epsilon}} \text{KL}(u \parallel \tilde{u}^{(t+1)}). \quad (26)$$

8. Retorne a iteração com menor $\lambda_{\max}(M^{(t)})$.

7 Benchmarks implementados

O projeto compara a carteira robusta com os benchmarks do artigo.

7.1 Equal Weight

A carteira equally weighted (EW) aloca igualmente:

$$w_i = \frac{1}{N}, \quad i = 1, \dots, N. \quad (27)$$

Ela é simples, robusta a erro de estimação e frequentemente difícil de superar em estudos empíricos.

7.2 GMV amostral

Usa a covariância amostral:

$$\hat{\Sigma} = \frac{1}{T-1} \sum_{t=1}^T (X_t - \bar{X})(X_t - \bar{X})^\top. \quad (28)$$

Os pesos são:

$$\hat{w}_{\text{GMV}} = \frac{\hat{\Sigma}^{-1} \mathbf{1}}{\mathbf{1}^\top \hat{\Sigma}^{-1} \mathbf{1}}. \quad (29)$$

7.3 GMV Long Only

Resolve o mesmo problema de mínima variância, mas com restrição adicional:

$$w_i \geq 0, \quad \mathbf{1}^\top w = 1. \quad (30)$$

Neste estudo, essa carteira é resolvida por projected gradient descent no simplex.

7.4 Linear Shrinkage

O estimador de Ledoit e Wolf combina a covariância amostral com um alvo estruturado:

$$\widehat{\Sigma}_{\text{lin}} = \rho F + (1 - \rho) \widehat{\Sigma}. \quad (31)$$

Na implementação empírica, usa-se o estimador linear de Ledoit–Wolf com alvo estruturado.

7.5 Nonlinear Shrinkage

O nonlinear shrinkage preserva os autovetores amostrais e transforma os autovalores de modo não linear. Se

$$\widehat{\Sigma} = U \Lambda U^\top, \quad (32)$$

então o estimador tem a forma

$$\widehat{\Sigma}_{\text{nlin}} = U \widetilde{\Lambda} U^\top, \quad (33)$$

em que os autovalores em $\widetilde{\Lambda}$ são versões encolhidas de forma não linear.

O estudo usa uma versão espectral inspirada em Ledoit e Wolf (2017), baseada em uma aproximação suavizada do Stieltjes transform. A matriz resultante foi verificada quanto à simetria e positividade dos autovalores, propriedades necessárias para que o estimador seja compatível com um problema de variância.

7.6 GMV Robust

A carteira robusta é:

$$w_0 = \frac{1}{N} \mathbf{1}, \quad w_s = \Pi_1 [w_{s-1} - \eta \widehat{a}(w_{s-1})], \quad (34)$$

em que $\widehat{a}(w)$ é o estimador robusto de Σw construído por blocos e HLZ.

8 Dados brasileiros

O universo brasileiro usado no experimento foi congelado após a aplicação dos filtros de histórico. Ao final desse procedimento, permaneceram 54 ativos elegíveis. Congelar o universo é importante porque a carteira teórica do Ibovespa muda ao longo do tempo. Sem congelamento, uma repetição futura do estudo poderia usar outro conjunto de ativos e produzir resultados não comparáveis.

O benchmark de mercado é o Ibovespa, usado como referência para avaliar se as carteiras otimizadas entregam desempenho competitivo contra uma alternativa ampla e observável do mercado brasileiro.

$$I_t = \text{nível do Ibovespa no dia } t. \quad (35)$$

9 Backtest

9.1 Janelas móveis

O artigo usa janelas de 12 e 24 meses, aproximadamente:

$$T = 252 \quad \text{e} \quad T = 500. \quad (36)$$

As duas janelas foram avaliadas separadamente. Para cada data de rebalanceamento, usa-se apenas a informação disponível nos T dias anteriores, estima-se a carteira e aplica-se essa alocação ao período seguinte. Esse desenho evita usar informação futura no cálculo dos pesos.

9.2 Retornos brutos e líquidos

O retorno bruto da carteira no dia t é

$$R_{p,t}^{\text{gross}} = w^\top X_t. \quad (37)$$

O retorno líquido desconta custos de transação no dia de rebalanceamento:

$$R_{p,t}^{\text{net}} = R_{p,t}^{\text{gross}} - c \cdot \text{TO}_t, \quad (38)$$

em que $c = 0.005$ corresponde a 50 bps, como no artigo.

9.3 Turnover

O turnover mede quanto a carteira precisa negociar para sair dos pesos imediatamente antes do rebalanceamento e chegar aos novos pesos-alvo.

Se $w_{j,l+}$ é o peso do ativo j imediatamente antes do rebalanceamento e $w_{j,l+1}$ é o novo peso-alvo, então:

$$\text{TO} = \frac{1}{L} \sum_{l=1}^L \sum_{j=1}^N |w_{j,l+1} - w_{j,l+}|. \quad (39)$$

O target turnover remove o efeito do drift de preços:

$$\text{TTO} = \frac{1}{L} \sum_{l=1}^L \sum_{j=1}^N |w_{j,l+1} - w_{j,l}|. \quad (40)$$

10 Métricas

10.1 Riqueza acumulada

Com riqueza inicial $W_0 = 1$, a riqueza acumulada é

$$W_t = \prod_{s=1}^t (1 + R_{p,s}). \quad (41)$$

10.2 Volatilidade anualizada

Se os retornos são diários:

$$\sigma_{\text{ann}} = \sqrt{252} \text{sd}(R_{p,t}). \quad (42)$$

10.3 Sharpe Ratio

Com taxa livre de risco diária igual a zero no projeto:

$$\text{SR} = \sqrt{252} \frac{\bar{R}_p}{\text{sd}(R_p)}. \quad (43)$$

10.4 Maximum Drawdown e Calmar

O drawdown em t é

$$DD_t = \frac{W_t}{\max_{s \leq t} W_s} - 1. \quad (44)$$

O máximo drawdown é o menor valor dessa série. O Calmar ratio é

$$\text{Calmar} = \frac{\text{retorno anualizado}}{|\text{MDD}|}. \quad (45)$$

10.5 Estatísticas dos pesos

O projeto calcula:

- peso mínimo médio;
- peso máximo médio;
- desvio padrão médio dos pesos;
- distância média para EW, chamada `mad_ew`;
- amplitude média `max_minus_min`;
- número efetivo de ativos.

O número efetivo de ativos é

$$N_{\text{eff}} = \frac{1}{\sum_{i=1}^N w_i^2}. \quad (46)$$

11 Testes estatísticos

O artigo reporta p-valores em relação à carteira GMV Robust. O projeto implementa:

- t-test pareado para turnover e target turnover;
- teste HAC/Newey–West via delta method para Sharpe;
- teste HAC/Newey–West via delta method para variância.

Para Sharpe e variância, usa-se a série de momentos:

$$m_t = (R_{x,t}, R_{y,t}, R_{x,t}^2, R_{y,t}^2), \quad (47)$$

em que x é a carteira comparada e y é a GMV Robust. A covariância de longo prazo dos momentos é estimada por Newey–West:

$$\hat{\Omega} = \hat{\Gamma}_0 + \sum_{\ell=1}^q \left(1 - \frac{\ell}{q+1}\right) (\hat{\Gamma}_\ell + \hat{\Gamma}_\ell^\top). \quad (48)$$

O delta method transforma a incerteza dos momentos em incerteza da estatística desejada.

12 Resultados empíricos recentes

As tabelas abaixo resumem resultados líquidos obtidos no projeto com dados brasileiros, universo congelado e custo de transação de 50 bps.

12.1 Janela $T = 252$

Tabela 2: Resultados líquidos das carteiras para janela de estimação $T = 252$.

Carteira	Sharpe	Calmar	TO	TTO
EW	0.509	0.210	0.065	0.000
GMV	0.412	0.186	0.988	0.956
GMV Long Only	0.537	0.218	0.076	0.042
GMV Linear Shrinkage	0.654	0.334	0.528	0.503
GMV Nonlinear Shrinkage	0.553	0.263	0.733	0.705
GMV Robust	0.713	0.317	0.370	0.358
Index	0.468	0.182	0.000	0.000

Para $T = 252$, a carteira robusta apresenta Sharpe superior aos benchmarks listados e turnover menor que GMV e shrinkage, mas maior que EW e GMV Long Only. O resultado é coerente com a ideia do artigo: a robustificação reduz instabilidade em relação aos métodos plug-in e shrinkage, sem impor a restrição long-only.

12.1.1 Gráficos para $T = 252$

A Figura 1 mostra a riqueza acumulada líquida das carteiras. Essa figura é a tradução visual da sequência

$$V_t = \prod_{s=1}^t (1 + r_s^{\text{net}}),$$

em que r_s^{net} já desconta o custo de transação. Para alunos iniciantes, é útil ler esse gráfico como uma simulação de “um real investido” no início do backtest. Curvas mais altas indicam maior crescimento acumulado, mas a inclinação e as quedas também importam: uma curva que cresce muito e depois cai fortemente pode ter Sharpe ou Calmar pior.

A Figura 2 mostra o turnover ao longo do tempo. O ponto central do paper é que uma carteira pode parecer boa antes de custos, mas tornar-se pouco atraente se exige trocas excessivas de posição. Por isso, turnover não é uma métrica acessória: ele mede a estabilidade operacional da regra de investimento.

A Figura 3 resume o comportamento dos pesos da carteira robusta. Como o método robusto não impõe a restrição long-only, pesos negativos podem aparecer. Isso não é um erro: eles correspondem a posições vendidas, permitidas pelo problema GMV com apenas a restrição orçamentária $\mathbf{1}^\top w = 1$. A interpretação estatística é que o método tenta reduzir a variância total da carteira usando a estrutura de covariância estimada de modo robusto.




Figura 1: Riqueza acumulada líquida para a janela de estimação $T = 252$.




Figura 2: Turnover das carteiras para a janela $T = 252$.

Tabela 3: Resultados líquidos das carteiras para janela de estimação $T = 500$.

Carteira	Sharpe	Calmar	TO	TTO
EW	0.596	0.465	0.064	0.000
GMV	0.892	0.447	0.495	0.451
GMV Long Only	0.713	0.629	0.064	0.019
GMV Linear Shrinkage	1.010	0.570	0.335	0.292
GMV Nonlinear Shrinkage	0.956	0.501	0.425	0.383
GMV Robust	0.932	0.824	0.280	0.266
Index	0.708	0.453	0.000	0.000




Figura 3: Pesos da carteira GMV Robust ao longo do tempo para $T = 252$.




Figura 4: Distribuição dos pesos das carteiras para $T = 252$.

12.2 Janela $T = 500$

Para $T = 500$, a carteira robusta tem turnover menor que GMV e shrinkage e apresenta o maior Calmar entre as carteiras reportadas. Esse padrão é alinhado com a motivação do artigo: estabilizar pesos e reduzir custos, preservando desempenho fora da amostra.

12.2.1 Gráficos para $T = 500$

Com $T = 500$, a janela de estimação é mais longa. Isso tende a reduzir ruído estatístico, pois cada covariância é estimada com mais observações, mas também pode tornar a carteira mais lenta para reagir a mudanças recentes de mercado. A Figura 5 mostra a riqueza acumulada líquida nesse cenário.




Figura 5: Riqueza acumulada líquida para a janela de estimação $T = 500$.

A Figura 6 reforça uma das conclusões mais importantes do experimento: com janela maior, a carteira robusta mantém turnover inferior ao dos métodos GMV amostral e shrinkage, ao mesmo tempo em que preserva desempenho competitivo. Em termos práticos, isso significa que a robustificação não está apenas melhorando uma métrica estatística abstrata; ela está produzindo uma regra de alocação menos instável.

13 Conclusões do experimento

O experimento confirma, nos dados brasileiros usados neste trabalho, a mensagem principal do artigo *Robustifying Markowitz*: em carteiras de mínima variância, a dificuldade central não é apenas resolver o problema quadrático, mas estimar de modo estável o objeto que entra no gradiente. O método robusto evita depender diretamente da inversão de uma matriz de covariância ruidosa e, em vez disso, estima robustamente Σw a cada passo do PGD.

À luz da hipótese de pesquisa, a evidência empírica é favorável, mas não absoluta. A carteira GMV Robust apresenta menor instabilidade que GMV amostral e que os métodos de shrinkage nas duas janelas analisadas, quando a instabilidade é medida por turnover




Figura 6: Turnover das carteiras para a janela $T = 500$.




Figura 7: Pesos da carteira GMV Robust ao longo do tempo para $T = 500$.




Figura 8: Distribuição dos pesos das carteiras para $T = 500$.

e target turnover. Em desempenho líquido, a robusta domina os benchmarks em alguns critérios, como Sharpe em $T = 252$ e Calmar em $T = 500$, mas não domina todos os critérios simultaneamente. Assim, a conclusão adequada é que a hipótese é **parcialmente sustentada**: há evidência clara de maior estabilidade e evidência competitiva de desempenho líquido fora da amostra, embora a superioridade não seja uniforme em todas as métricas.

Para a janela $T = 252$, a carteira GMV Robust obteve o maior Sharpe líquido entre as carteiras reportadas. Ela também reduziu fortemente o turnover em relação à GMV amostral e às carteiras de shrinkage. Esse resultado é pedagogicamente importante: robustez não significa apenas “ignorar outliers”. Neste projeto, robustez significa construir uma regra de decisão menos sensível a blocos de observações extremos ou instáveis.

Para a janela $T = 500$, a carteira de shrinkage linear apresentou o maior Sharpe, mas a GMV Robust apresentou o maior Calmar e menor turnover que GMV, shrinkage linear e nonlinear shrinkage. Isso sugere uma conclusão mais fina: o método robusto não domina todos os critérios em todos os cenários, mas entrega uma combinação atraente de desempenho, controle de drawdown e estabilidade de pesos. Em aplicações reais, essa combinação pode ser mais relevante do que maximizar apenas Sharpe.

O benchmark do índice também é importante. Comparar somente carteiras otimizadas entre si pode esconder o fato de que uma regra sofisticada precisa superar uma alternativa simples e investível. Nos dois tamanhos de janela, as carteiras otimizadas mais estáveis entregam métricas competitivas contra o índice, mas com perfis diferentes de risco, turnover e drawdown.

A principal conclusão técnica é que o projeto está coerente com a lógica matemática do paper: usa PGD, projeção orçamentária, estimação robusta da ação Σw , agregação HLZ/spectral reweighting, rebalanceamento mensal, custos de transação e comparação com benchmarks clássicos. O diferencial deste estudo é trocar o universo empírico original por ativos brasileiros, preservando a estrutura conceitual do experimento.

14 Validações metodológicas

14.1 Auditoria HLZ

Para verificar o comportamento do agregador HLZ, foi construído um exemplo contaminado e avaliado se o procedimento:

- respeita o cap de pesos em $W_{\ell,\epsilon}$;
- reduz a norma espectral ponderada em relação aos pesos uniformes.

Na última execução, o raio ponderado uniforme foi 27.151586 e o raio ponderado HLZ foi 1.615178, com peso máximo 0.149461 e cap 0.150000.

14.2 Validação do nonlinear shrinkage

O estimador de nonlinear shrinkage foi validado verificando duas propriedades fundamentais da matriz estimada: simetria e autovalores positivos. Essas condições são importantes porque uma matriz de covariância deve ser simétrica e semidefinida positiva. Também foi prevista a possibilidade de comparação contra uma matriz de referência externa, caso uma implementação oficial do estimador seja usada como base de validação.

15 Limitações e pontos de atenção

O projeto está alinhado com a lógica central do artigo, mas há pontos que devem ser lidos com cuidado:

1. O nonlinear shrinkage usa uma implementação espectral interna. Para validação numérica literal, deve-se comparar contra a implementação original de Ledoit–Wolf.
2. A truncagem robusta usa quantil empírico da norma, pois o parâmetro teórico exato depende de constantes desconhecidas na prática.
3. O universo brasileiro é congelado com ativos que passaram pelo filtro de histórico. Essa é uma escolha de reprodutibilidade, mas não é uma carteira teórica dinâmica da B3.
4. A fonte de preços pode revisar ou ajustar séries históricas; por isso a preservação das bases usadas no estudo é parte importante da reprodutibilidade.
5. O custo computacional do HLZ é maior que o de uma mediana coordenada simples. Isso é esperado, pois o método usa autovalores/autovetores e reponderação iterativa.

16 Conclusão

Este trabalho implementa uma versão aplicada ao Brasil da lógica de *Robustifying Markowitz*. A contribuição central é substituir a dependência direta em $\widehat{\Sigma}^{-1}$ por um procedimento iterativo que estima robustamente Σw . Essa troca é fundamental em ambientes com alta dimensão, amostras finitas e caudas pesadas.

Para alunos iniciando em Estatística Robusta, o projeto ilustra três ideias importantes:

1. robustez não é apenas “remover outliers”, mas controlar a influência deles em um problema de otimização;
2. em alta dimensão, estimar uma matriz inteira pode ser mais difícil do que estimar sua ação em direções relevantes;
3. métricas financeiras como turnover e custos de transação são parte essencial da avaliação estatística de carteiras.

O resultado final é um procedimento reprodutível que combina teoria robusta moderna, otimização convexa e avaliação empírica em dados brasileiros.

Referências

- [1] Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91.
- [2] Ledoit, O. and Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- [3] Ledoit, O. and Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *The Review of Financial Studies*, 30(12), 4349–4388.
- [4] Ledoit, O. and Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- [5] Ledoit, O. and Wolf, M. (2011). Robust performance hypothesis testing with the variance. *Wilmott*, 2011(55), 86–89.
- [6] Hopkins, S. B., Li, J. and Zhang, F. (2020). Robust and Heavy-Tailed Mean Estimation Made Simple, via Regret Minimization. arXiv:2007.15839.
- [7] Haerdle, W. K., Klochov, Y., Petukhina, A. and Zhivotovskiy, N. (2022). Robustifying Markowitz. arXiv:2212.13996.
- [8] Newey, W. K. and West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.